

## FICHA 09 – resolução

DPC

1. Considere uma amostra de tamanho  $n$  de uma variável aleatória  $X$  com distribuição Poisson (fdp a seguir).

$$f_X(x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

Calcule o estimador de  $\lambda$  pelo método da máxima verosimilhança.

**Resolução:**

Dada uma função de probabilidade  $f_X$  com  $k$  parâmetros desconhecidos  $\theta_1, \theta_2, \dots, \theta_k$  e dadas  $n$  amostras  $x_1, x_2, \dots, x_n$ , obtidas de forma independente e a partir da mesma distribuição  $f_X$ , o método da máxima verosimilhança procura os valores dos parâmetros que maximizam a probabilidade conjunta das amostras observadas:

$$(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) = \underset{\theta_1, \theta_2, \dots, \theta_k}{\operatorname{argmax}} P(X_1 = x_1 \wedge X_2 = x_2 \wedge \dots \wedge X_n = x_n).$$

Como (se assume que) as amostras são independentes, temos:

$$P(X_1 = x_1 \wedge X_2 = x_2 \wedge \dots \wedge X_n = x_n) = P(X_1 = x_1)P(X_2 = x_2) \dots P(X_n = x_n) = \prod_{i=1}^n P(X_i = x_i).$$

Como todas as amostras seguem a distribuição  $f_X$ , temos  $P(X_i = x_i) = f_X(x_i)$  para todo o  $i$  e, assim:

$$\prod_{i=1}^n P(X_i = x_i) = \prod_{i=1}^n f_X(x_i) = \mathcal{L}(\theta_1, \theta_2, \dots, \theta_k).$$

Queremos então encontrar  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$  que maximizam  $\mathcal{L}(\theta_1, \theta_2, \dots, \theta_k)$ . Se  $f_X$  for contínua e diferenciável em relação aos respetivos parâmetros, a solução está entre os pontos onde o gradiente de  $\mathcal{L}$  é nulo:

$$\nabla \mathcal{L}(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) = 0 \Leftrightarrow \begin{cases} \frac{\partial \mathcal{L}}{\partial \theta_1}(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) = 0 \\ \frac{\partial \mathcal{L}}{\partial \theta_2}(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) = 0 \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial \theta_k}(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) = 0 \end{cases}.$$

Note que o cálculo destas derivadas implica o cálculo da derivada de um produto, que pode ser bastante trabalhoso (e pouco estável numericamente). Para o evitar, em vez de maximizarmos  $\mathcal{L}$  diretamente, podemos maximizar  $\log \mathcal{L}$ , visto que a função logaritmo não altera a posição do maximizante (porquê?). Temos, então:

$$\log \mathcal{L}(\theta_1, \theta_2, \dots, \theta_k) = \log \left( \prod_{i=1}^n f_X(x_i) \right) = \sum_{i=1}^n \log f_X(x_i),$$

e assim transformámos o produto numa soma (de logaritmos). Como a posição do maximizante se mantém, restaria agora resolver  $\nabla \log \mathcal{L}(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) = 0$ .

Neste exercício, temos:

$$\mathcal{L}(\lambda) = \prod_{i=1}^n f_X(x_i) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!}.$$

Podemos resolver de imediato através de  $\frac{d\mathcal{L}}{d\lambda}(\hat{\lambda}) = 0$  ou aplicar previamente o logaritmo, como sugerido anteriormente. Vamos resolver utilizando  $\log \mathcal{L}$  e deixamos a outra resolução como exercício:

$$\begin{aligned}\log \mathcal{L}(\lambda) &= \sum_{i=1}^n \log \left( \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} \right) \\ &= \sum_{i=1}^n (-\lambda + x_i \log \lambda - \log x_i!) \\ &= -n\lambda + \log(\lambda) \sum_{i=1}^n x_i - \sum_{i=1}^n \log x_i! \\ \frac{d \log \mathcal{L}}{d\lambda}(\hat{\lambda}) &= 0 \Leftrightarrow -n + \frac{1}{\hat{\lambda}} \sum_{i=1}^n x_i = 0 \Leftrightarrow \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n x_i, \quad (\text{estimativa}) \\ \hat{\lambda} &= \frac{1}{n} \sum_{i=1}^n X_i. \quad (\text{estimador})\end{aligned}$$

Nota: Em rigor, só demonstrámos que  $\hat{\lambda} = (1/n) \sum_{i=1}^n x_i$  é um ponto crítico de  $\mathcal{L}$ , faltando verificar que se trata de facto de um maximizante. Essa verificação pode ser feita de forma simples (por exemplo, pelo sinal da segunda derivada), pelo que é deixada como exercício. Para além disso, neste tipo de problemas, quando a solução obtida é única, sabemos que será necessariamente um maximizante e assim podemos ignorar esta verificação.

2. Considere uma amostra de tamanho  $n$  de uma variável aleatória com distribuição

$$f(x) = \frac{1}{\theta^2} x e^{-x/\theta}, \quad 0 \leq x < \infty$$

Calcule o estimador de máxima verosimilhança de  $\theta$ .

### Resolução:

Neste caso, temos uma distribuição contínua, mas o método de resolução é exatamente igual. A discussão elaborada no exercício anterior permanece válida, com a única diferença de que, agora, estamos a maximizar a densidade de probabilidade (e não a probabilidade) conjunta das  $n$  amostras independentes.

$$\begin{aligned}\log \mathcal{L}(\theta) &= \sum_{i=1}^n \log f(X_i) = \sum_{i=1}^n \left( -2 \log \theta + \log X_i - \frac{X_i}{\theta} \right) \\ &= -2n \log \theta + \sum_{i=1}^n \log X_i - \frac{1}{\theta} \sum_{i=1}^n X_i, \\ \frac{d \log \mathcal{L}}{d\theta}(\hat{\theta}) &= 0 \Leftrightarrow \hat{\theta} = \frac{1}{2n} \sum_{i=1}^n X_i.\end{aligned}$$

Sugestão: Compare este estimador com o obtido pelo método dos momentos (ex. 6 da Ficha 8).

3. Uma variável aleatória  $X$  tem fdp  $f(x) = (\beta + 1)x^\beta, 0 < x < 1$ .

- Determine a estimativa de Máxima Verosimilhança de  $\beta$  baseado numa amostra de tamanho  $n$ .
- Calcule a estimativa quando os valores amostrais forem 0.3; 0.8; 0.27; 0.35; 0.62; 0.55. Sabe-se que a soma destes valores é 2.89, o produto é 0.0077, o logaritmo da soma é 1.0613 e o logaritmo do produto é -4.8621.

### Resolução:

- 

$$\begin{aligned}\log \mathcal{L}(\beta) &= \sum_{i=1}^n \log f(x_i) = \sum_{i=1}^n (\log(\beta + 1) + \beta \log x_i) = n \log(\beta + 1) + \beta \sum_{i=1}^n \log x_i, \\ \frac{d \log \mathcal{L}}{d\beta}(\hat{\beta}) &= 0 \Leftrightarrow \frac{n}{\hat{\beta} + 1} + \sum_{i=1}^n \log x_i \Leftrightarrow \hat{\beta} = -1 - \frac{n}{\sum_{i=1}^n \log x_i}.\end{aligned}$$

(b)  $n = 6, \sum_{i=1}^6 \log x_i = \log \left( \prod_{i=1}^6 x_i \right) = -4.8621 \implies \hat{\beta} \approx 0.234.$

Sugestão: Compare o estimador e a estimativa obtidos com os que se obtêm pelo método dos momentos (ex. 7 da Ficha 8).

4. Temos duas máquinas para produção de um dispositivo semiconductor com um comprimento médio de  $\mu$ . No entanto, a máquina 1 é mais nova do que a máquina 2. Portanto, a variância da máquina 1 é  $\sigma_1^2$  e a variância da máquina 2 é  $\sigma_2^2 = a\sigma_1^2$  com  $a \geq 1$ . Suponha que temos  $n_1$  observações da máquina 1 e  $n_2$  observações da máquina 2.

- (a) Demonstrar que  $\hat{\mu} = \alpha \bar{X}_1 + (1 - \alpha) \bar{X}_2$  é um estimador sem tendência para  $\mu$  com  $\alpha \in [0, 1]$ .  
 (b) Qual é o erro padrão do estimador da alínea anterior?  
 (c) Qual é o valor de  $\alpha$  que minimiza o erro padrão do estimador de  $\mu$ .  
 (d) Suponha que  $a = 4$  e  $n_1 = 2n_2$ . Qual é o valor de  $\alpha$  que minimiza o erro padrão? Quanto seria a diferença se o  $\alpha$  fosse arbitrariamente escolhido como  $\alpha = 1/2$ ?

**Resolução:**

(a)  $E(X_1) = E(X_2) = \mu, V(X_1) = \sigma^2, V(X_2) = a\sigma^2, a \geq 1.$

$$\bar{X}_1 = \frac{1}{n_1} \sum_{i=1}^{n_1} X_{1,i} \implies E(\bar{X}_1) = \mu,$$

$$\bar{X}_2 = \frac{1}{n_2} \sum_{i=1}^{n_2} X_{2,i} \implies E(\bar{X}_2) = \mu,$$

$$E(\hat{\mu}) = E(\alpha \bar{X}_1 + (1 - \alpha) \bar{X}_2) = \alpha E(\bar{X}_1) + (1 - \alpha) E(\bar{X}_2) = \mu. \quad \square$$

- (b) Assumindo que as amostras de cada máquina são independentes entre si e entre as duas máquinas, temos:

$$V(\bar{X}_1) = V\left(\frac{1}{n_1} \sum_{i=1}^{n_1} X_{1,i}\right) = \frac{1}{n_1^2} \sum_{i=1}^{n_1} V(X_{1,i}) = \frac{1}{n_1^2} \sum_{i=1}^{n_1} \sigma^2 = \frac{\sigma^2}{n_1}, \quad V(\bar{X}_2) = \frac{a\sigma^2}{n_2},$$

$$\begin{aligned} V(\hat{\mu}) &= V(\alpha \bar{X}_1 + (1 - \alpha) \bar{X}_2) = \alpha^2 V(\bar{X}_1) + (1 - \alpha)^2 V(\bar{X}_2) \\ &= \frac{\alpha^2 \sigma^2}{n_1} + \frac{(1 - \alpha)^2 a \sigma^2}{n_2}, \end{aligned}$$

$$\varepsilon = \sqrt{E[(\hat{\mu} - \mu)^2]} = \sqrt{(E(\hat{\mu} - \mu))^2 + V(\hat{\mu})} = \sqrt{V(\hat{\mu})} = \sqrt{\frac{\alpha^2 \sigma^2}{n_1} + \frac{(1 - \alpha)^2 a \sigma^2}{n_2}}.$$

- (c)

$$\frac{d\varepsilon}{d\alpha}(\alpha^*) = 0 \Leftrightarrow \alpha^* = \frac{an_1}{an_1 + n_2}.$$

(d)  $a = 4, n_1 = 2n_2 \implies \alpha^* = 8/9, \quad \varepsilon(\alpha = 8/9)/\varepsilon(\alpha = 1/2) \approx 0.628.$

5.  $X_1, X_2, \dots, X_n$  é uma amostra aleatória de uma distribuição normal com média  $\mu$  e variância  $\sigma^2$ . Sejam  $X_{\min}$  e  $X_{\max}$  o menor e o maior valor na amostra, respectivamente.

- (a) O estimador  $\frac{X_{\min} + X_{\max}}{2}$  tem tendência?  
 (b) Calcule o erro padrão deste estimador.  
 (c) Que estimador utilizaria, a média aritmética ou este estimador?

**Resolução:**

(Este exercício é difícil!)

- (a) Seja  $X \sim N(\mu, \sigma^2)$ . Pretende-se averiguar a tendência do estimador  $\hat{\mu} = (X_{\min} + X_{\max})/2$  para a média  $\mu$  da distribuição. Como habitualmente, temos um conjunto de  $n$  observações independentes da v.a.  $X$ . Como  $X_{\max}$  é, por definição, o valor máximo da amostra, se  $X_{\max}$  é majorado um dado  $x$ , então todos os valores da amostra são majorados por esse  $x$ , ou seja:

$$X_{\max} \leq x \Leftrightarrow X_1 \leq x \wedge X_2 \leq x \wedge \cdots \wedge X_n \leq x.$$

Assim, a função de distribuição acumulada de  $X_{\max}$  é dada por:

$$\begin{aligned} F_{X_{\max}}(x) &= P(X_{\max} \leq x) \\ &= P(X_1 \leq x \wedge X_2 \leq x \wedge \cdots \wedge X_n \leq x) \\ &= P(X_1 \leq x)P(X_2 \leq x) \cdots P(X_n \leq x) && (X_i \text{ indep.}) \\ &= P(X \leq x)^n && (X_i \stackrel{d}{=} X) \\ &= F_X(x)^n, \end{aligned}$$

onde  $F_X$  é a função de distribuição acumulada de  $X$ . A função densidade de probabilidade de  $X_{\max}$  é, então:

$$f_{X_{\max}}(x) = \frac{d}{dx} F_{X_{\max}}(x) = n f_X(x) F_X(x)^{n-1},$$

onde  $f_X = dF_X/dx$  é a função densidade de probabilidade de  $X$ . Uma vez encontrada  $f_{X_{\max}}$ , estamos em condições de escrever uma expressão para  $E(X_{\max})$ :

$$E(X_{\max}) = \int_{-\infty}^{\infty} x f_{X_{\max}}(x) dx = n \int_{-\infty}^{\infty} x f_X(x) F_X(x)^{n-1} dx.$$

Relativamente ao mínimo da amostra ( $X_{\min}$ ) aplica-se o raciocínio recíproco: se  $X_{\min}$  é minorado por um dado  $x$ , então todos os valores da amostra são minorados por esse  $x$ , ou seja:

$$X_{\min} > x \Leftrightarrow X_1 > x \wedge X_2 > x \wedge \cdots \wedge X_n > x.$$

Assim, a função de distribuição acumulada de  $X_{\min}$  é:

$$\begin{aligned} F_{X_{\min}}(x) &= P(X_{\min} \leq x) = 1 - P(X_{\min} > x) \\ &= 1 - P(X_1 > x \wedge X_2 > x \wedge \cdots \wedge X_n > x) \\ &= 1 - P(X_1 > x)P(X_2 > x) \cdots P(X_n > x) && (X_i \text{ indep.}) \\ &= 1 - P(X > x)^n && (X_i \stackrel{d}{=} X) \\ &= 1 - (1 - P(X \leq x))^n = 1 - (1 - F_X(x))^n \end{aligned}$$

e a função densidade e valor esperado correspondentes ficam, respetivamente:

$$f_{X_{\min}}(x) = \frac{d}{dx} F_{X_{\min}}(x) = n f_X(x) (1 - F_X(x))^{n-1},$$

$$E(X_{\min}) = \int_{-\infty}^{\infty} x f_{X_{\min}}(x) dx = n \int_{-\infty}^{\infty} x f_X(x) (1 - F_X(x))^{n-1} dx.$$

A partir das expressões que obtivemos para  $E(X_{\max})$  e  $E(X_{\min})$ , podemos escrever a expressão resultante para o valor esperado do estimador  $\hat{\mu}$ :

$$\begin{aligned} E(\hat{\mu}) &= E\left(\frac{X_{\min} + X_{\max}}{2}\right) = \frac{E(X_{\min}) + E(X_{\max})}{2} \\ &= \frac{n}{2} \int_{-\infty}^{\infty} x f_X(x) (1 - F_X(x))^{n-1} dx + \frac{n}{2} \int_{-\infty}^{\infty} x f_X(x) F_X(x)^{n-1} dx. \end{aligned}$$

Note que, até ao momento, não utilizámos a informação de que  $X$  segue uma distribuição normal. Agora, iremos utilizá-la, tirando partido das propriedades dessa distribuição (em particular, da simetria) para prosseguir a resolução. Recorde que a distribuição  $N(\mu, \sigma^2)$  é simétrica em torno de  $\mu$ ,

logo  $f_X(\mu + x) = f_X(\mu - x)$  para todo o  $x$ , assim:

$$\begin{aligned}
 F_X(x) &= \int_{-\infty}^x f_X(x') dx' \\
 &= \int_{-\infty}^x f_X(2\mu - x') dx' \quad (f_X(x') = f_X(\mu + (x' - \mu)) \stackrel{\text{simetria}}{=} f_X(\mu - (x' - \mu)) = f_X(2\mu - x')) \\
 &= \int_{2\mu-x}^{\infty} f_X(t) dt \quad (t = 2\mu - x', \quad dt = -dx') \\
 &= P(X > 2\mu - x) \\
 &= 1 - F_X(2\mu - x)
 \end{aligned}$$

Fazendo a substituição  $1 - F_X(x) = F_X(2\mu - x)$  na expressão para  $E(\hat{\mu})$ , obtém-se:

$$\begin{aligned}
 E(\hat{\mu}) &= \frac{n}{2} \int_{-\infty}^{\infty} x f_X(x) F_X(2\mu - x)^{n-1} dx + \frac{n}{2} \int_{-\infty}^{\infty} x f_X(x) F_X(x)^{n-1} dx \\
 &\quad (x \leftarrow 2\mu - x, \quad dx \leftarrow -dx) \\
 &= \frac{n}{2} \int_{-\infty}^{\infty} (2\mu - x) f_X(2\mu - x) F_X(x)^{n-1} dx + \frac{n}{2} \int_{-\infty}^{\infty} x f_X(x) F_X(x)^{n-1} dx \\
 &\quad (f_X(2\mu - x) = f_X(x)) \\
 &= \frac{n}{2} \int_{-\infty}^{\infty} (2\mu - x) f_X(x) F_X(x)^{n-1} dx + \frac{n}{2} \int_{-\infty}^{\infty} x f_X(x) F_X(x)^{n-1} dx \\
 &= \mu \int_{-\infty}^{\infty} n f_X(x) F_X(x)^{n-1} dx \\
 &= \mu \int_{-\infty}^{\infty} \frac{d}{dx} F_X(x)^n dx \\
 &= \mu [F_X(x)^n]_{-\infty}^{\infty} = \mu(1^n - 0^n) = \mu,
 \end{aligned}$$

logo  $\hat{\mu}$  é um estimador centrado de  $\mu$ .

(b) –

- (c) A média amostral (isto é, a média aritmética dos valores da amostra) é menos sensível do que  $\hat{\mu}$  a valores extremos, logo apresenta menor variância. Assim, como ambos os estimadores são centrados, apresenta também menor erro padrão, pelo que escolheríamos a média amostral.

Sugestão: Através de simulação computacional, confirme empiricamente que: i) ambos os estimadores são centrados; ii) a variância da média amostral é inferior à variância de  $\hat{\mu}$ ; iii) o erro padrão da média amostral é inferior ao erro padrão de  $\hat{\mu}$ .

6. Uma variável aleatória  $X$  tem distribuição  $N(\mu, 1)$ . Tomam-se 20 observações de  $X$ , mas em vez de se registrar o valor real, anotamos somente se  $X$  era ou não negativo. Suponha que o evento  $\{X < 0\}$  tenha ocorrido exactamente 14 vezes. Utilizando essa informação, determine a estimativa de MV de  $\mu$ .

**Resolução:**

$X \sim N(\mu, 1)$ , vamos definir a v.a.  $Y$  tal que:

$$Y = \begin{cases} 0, & \text{se } X < 0 \\ 1, & \text{se } X \geq 0 \end{cases}.$$

Temos então 20 amostras  $y_1, y_2, \dots, y_{20}$  de valores de  $Y$  e sabemos que, entre estas, temos 14 amostras com o valor “0” (e, necessariamente, 6 amostras com o valor “1”). Assim,

$$\begin{aligned}
 \log \mathcal{L}(\mu) &= \sum_{i=1}^{20} \log f_Y(y_i) = 14 \log f_Y(0) + 6 \log f_Y(1) \\
 &= 14 \log P(Y = 0) + 6 \log P(Y = 1) = 14 \log \underbrace{P(X < 0)}_{1-p} + 6 \log \underbrace{P(X \geq 0)}_p \\
 &= 6 \log p + 14 \log(1 - p).
 \end{aligned}$$

Note que  $p = P(X \geq 0)$  depende de  $\mu$ , pelo que  $\log \mathcal{L}$  é função de  $\mu$ , como indicado. Pela regra da cadeia do cálculo de derivadas, temos:

$$\frac{d \log \mathcal{L}}{d\mu} = \frac{d \log \mathcal{L}}{dp} \frac{dp}{d\mu},$$

e, assim:

$$\begin{aligned} \frac{d \log \mathcal{L}}{d\mu}(\hat{\mu}) = 0 &\Leftrightarrow \frac{d \log \mathcal{L}}{dp}(p(\hat{\mu})) \frac{dp}{d\mu}(\hat{\mu}) = 0 \\ &\Leftrightarrow \frac{d \log \mathcal{L}}{dp}(p(\hat{\mu})) = 0 \vee \frac{dp}{d\mu}(\hat{\mu}) = 0. \end{aligned}$$

Observando que  $p(\mu)$  é uma função estritamente crescente (confirme!), concluimos que a sua derivada é sempre estritamente positiva, pelo que a equação  $\frac{dp}{d\mu}(\hat{\mu}) = 0$  não tem solução. Assim, resta-nos resolver:

$$\begin{aligned} \frac{d \log \mathcal{L}}{dp}(p(\hat{\mu})) = 0 &\Leftrightarrow \frac{d}{dp}(6 \log p + 14 \log(1 - p)) \Big|_{p=p(\hat{\mu})} = 0 \\ &\Leftrightarrow \frac{6}{p(\hat{\mu})} - \frac{14}{1 - p(\hat{\mu})} = 0 \Leftrightarrow p(\hat{\mu}) = \frac{3}{10}, \end{aligned}$$

$$\frac{3}{10} = p(\hat{\mu}) = P(X \geq 0) = P\left(\underbrace{\frac{X - \hat{\mu}}{1}}_{Z \sim N(0,1)} \geq \frac{0 - \hat{\mu}}{1}\right) = P(Z \geq -\hat{\mu}) \Leftrightarrow \hat{\mu} \approx -0.5244.$$